

PopOut

Monte Carlo Tree Search

Estratégias de Pesquisa Adversarial

Rafael Silva · Guilherme Varandas

Inteligência Artificial 2025/2026

O Jogo — PopOut

Mecânica base

- Variante do Connect-4 em tabuleiro 6×7
- DROP — colocar peça pelo topo de qualquer coluna
- POP — remover peça própria da base, peças acima descem
- Objectivo: alinhar 4 peças horizontal, vertical ou diagonal

Regras especiais

- | | |
|----|--|
| R1 | Pop simultâneo — quem faz o pop ganha |
| R2 | Tabuleiro cheio — pop ou declarar empate |
| R3 | Estado repetido 3× — empate declarável |

MCTS — As 4 Fases



Decisão final: filho com mais VISITAS (não mais wins)

Algoritmo MCTS com UCT

Fórmula UCT

$$UCT(n) = w/v + c \cdot \sqrt{\ln V / v}$$

w/v = taxa vitórias (exploração) $c \cdot \sqrt{\ln V / v}$ = exploração

Efeito do parâmetro c

$c = 1.4 (\sqrt{2})$ — padrão — equilíbrio exploração/exploração
 c alto — explora mais ramos novos
 c baixo — aprofunda os ramos mais promissores

Rollout heurístico

1. Jogar vitória imediata se existir
2. Bloquear vitória imediata do adversário
3. Top-3 candidatos por score heurístico + ruído aleatório
4. Pops prejudiciais filtrados (is_bad_pop)

Função Heurística

Avaliação por janelas de 4 células em todas as direcções

Configuração	Pts
4 peças próprias	+100 000
3 próprias + 1 vazio	+50
2 próprias + 2 vazios	+10
Peça coluna central	+4
3 adversário + 1 vazio	-80
2 adversário + 2 vazios	-8

Algoritmo alternativo — MCTS com ϵ -greedy

Política de Selecção

Com prob. $\epsilon=0.2$ → filho ALEATÓRIO (exploração)

Com prob. 0.8 → filho com MAIS VISITAS (exploração)

Comparação UCT vs ϵ -greedy

Aspecto	UCT (Alg. 1)	ϵ -greedy (Alg. 2)
Selecção	Fórmula matemática contínua	Decisão binária (aleatório ou melhor)
Parâmetro	c — exploração gradual	ϵ — probabilidade directa
Adaptatividade	Adapta-se à profundidade	ϵ fixo em toda a árvore
Garantia teórica	Óptimo para bandits	Sem garantia formal
Eficiência	Mais eficiente em espaços grandes	Perde 20% de iterações a explorar

Expansão · Simulação · Backpropagation são idênticos ao UCT — só a fase de Selecção muda

Resultados — UCT vs ϵ -greedy

18

90%

Vitórias UCT (X)

2

10%

Vitórias ϵ -greedy (O)

0

0%

Empates

Condições: 20 jogos · iterações iguais (1000) · $c = 1.4$ · $\epsilon = 0.2$ | X sempre UCT, O sempre ϵ -greedy

Por que o UCT ganha?

- 1 Adaptatividade:** UCT ajusta exploração/exploração dinamicamente — ϵ fixo não se adapta à posição na árvore
- 2 Eficiência:** $\epsilon=0.2$ desperdiça 20% das iterações em escolhas aleatórias mesmo quando o melhor ramo já está identificado
- 3 Garantia teórica:** UCT tem provas formais de convergência óptima — ϵ -greedy não

⚠ Nos testes iniciais o ϵ -greedy ganhava — por assimetria de iterações e bug no backpropagation. Após correção, UCT recuperou.

Árvore de Decisão ID3

O que é o ID3?

Algoritmo supervisionado que constrói uma árvore de decisão de forma “greedy”. Em cada nó, escolhe o atributo que mais reduz a incerteza sobre a classe.

No PopOut:

- 42 atributos (células do tabuleiro)
- Células: 1 (própria) | -1 (adversário) | 0 (vazia)
- Classe alvo: jogada do MCTS (drop_3, pop_2, ...)

Depois de treinada, escolhe jogadas quase instantaneamente. A qualidade depende do dataset e da profundidade máxima.

Entropia e Ganho de Informação

Entropia

$$H(S) = -\sum p(c) \cdot \log_2(p(c))$$

$H=0$ quando todos os exemplos têm a mesma classe. Máximo quando as classes estão equilibradas.

Ganho de Informação (categórico)

$$G(S,A) = H(S) - \sum |S_v|/|S| \cdot H(S_v)$$

Ganho de Informação (numérico, threshold t)

$$G(S,A,t) = H(S) - |S \leq t|/|S| \cdot H(S \leq t) - |S > t|/|S| \cdot H(S > t)$$

A árvore pára quando encontra classe pura, atinge **max_depth** ou nenhum atributo melhora a separação. As folhas guardam a classe prevista.

ID3 — Treino, Avaliação e Overfitting

Métricas de Avaliação

- Accuracy de treino:** mede a aprendizagem nos exemplos usados no treino
- Accuracy de teste:** capacidade de generalizar para estados novos
- Jogadas legais:** a jogada prevista é válida no estado atual?

No PopOut, a accuracy de teste pode ser limitada porque nem sempre existe uma única jogada correta. O ID3 pode prever uma jogada diferente da escolhida pelo MCTS, mas ainda assim válida e razoável.

Overfitting e Controlo

Acontece quando a árvore memoriza os exemplos de treino em vez de aprender padrões gerais. Com 42 atributos existem muitas combinações possíveis.

Num gráfico: accuracy de treino sobe, mas accuracy de teste estabiliza ou desce.

Impacto da profundidade máxima

Profundidade baixa


Underfitting — árvore simples demais

max_depth = 8

Equilíbrio recomendado

Outras formas de reduzir overfitting: mais e melhores exemplos, ganho mínimo mais elevado (**min_gain**), ou poda (**pruning**) após construir a árvore.

ID3 PopOut — Impacto da Profundidade Máxima



Leitura do gráfico

Treino (azul)

Sobe com a profundidade — overfitting

Teste (laranja)

Estabiliza ~40% — generalização limitada

Jogadas legais (verde)

Quase sempre 100% — validade garantida

max_depth = 8
equilíbrio recomendado

A accuracy de teste estabiliza porque existem várias jogadas igualmente válidas — o ID3 pode prever uma diferente da do MCTS mas ainda assim correcta. O ponto de inflexão em `max_depth = 8` representa o melhor equilíbrio entre aprendizagem e generalização.

Conclusões

Resultados

- UCT vence 18/20 (90%) com iterações iguais - confirma superioridade teórica
- UCT ajusta exploração dinamicamente; e-greedy perde 20% das iterações em escolhas aleatórias mesmo quando o melhor ramo já está identificado
- O ID3 permitiu obter um modelo rápido e interpretável para aproximar decisões geradas pelo MCTS.

Limitações

- ϵ fixo não se adapta às fases do jogo — na fase final, desperdiçar 20% das iterações é especialmente custoso
- Sem tabela de transposição: estados idênticos atingidos por caminhos diferentes são reavaliados do zero
- No ID3, a accuracy exata pode ser enganadora, porque existem várias jogadas possíveis e razoáveis.
- O desempenho do ID3 depende fortemente da qualidade do dataset, da profundidade máxima e do controlo de overfitting.